



BỘ CÔNG THƯƠNG
TRƯỜNG ĐẠI HỌC CÔNG THƯƠNG THÀNH PHỐ HỒ CHÍ MINH

KHAI THÁC DỮ LIỆU (KHAI PHÁ DỮ LIỆU)

Buổi 1:

TỔNG QUAN VÀ TIỀN XỬ LÝ DỮ LIỆU



Khai thác dữ liệu (Data Mining) là quá trình khám phá, phân tích và trích xuất **thông tin hữu ích** từ các tập dữ liệu lớn. Quá trình này sử dụng các kỹ thuật và thuật toán để tìm kiếm **mẫu**, **mối quan hệ** hoặc **tri thức** có giá trị ẩn giấu bên trong dữ liệu, từ đó hỗ trợ việc ra quyết định trong các lĩnh vực như kinh doanh, y tế, giáo dục, và nhiều ngành khác.

Câu hỏi: Hãy đưa ra một ví dụ thực tế mà khai thác dữ liệu có thể áp dụng.



Quy trình khai thác dữ liệu thường bao gồm

1. Thu thập dữ liệu
2. Tiền xử lý dữ liệu
3. Áp dụng thuật toán
4. Diễn giải kết quả

Câu hỏi: Làm sao để thu thập dữ liệu ?

Câu hỏi: Phân biệt tổng thể và mẫu.



Câu hỏi: Nếu dữ liệu có lỗi (nhiều hoặc thiếu), bước nào trong quy trình sẽ xử lý nó?



Câu hỏi: Tiền xử lý dữ liệu là làm những công việc gì ?



Tiền xử lý dữ liệu là một bước quan trọng và không thể thiếu trong quá trình khai thác tri thức từ dữ liệu. Quá trình này đảm bảo rằng dữ liệu đầu vào cho các thuật toán khai thác tri thức được tối ưu hóa về chất lượng, tính nhất quán và độ tin cậy.

- Cải thiện chất lượng dữ liệu
- Tăng hiệu quả của thuật toán khai thác dữ liệu
- Chuẩn bị dữ liệu phù hợp cho từng bài toán
- Giảm kích thước và độ phức tạp của dữ liệu
- Đảm bảo tính đáng tin cậy và khả năng diễn giải



Thế nào là dữ liệu nhiễu (noise) và dữ liệu ngoại lệ (outlier)





Dữ liệu nhiễu (Noise): Là những biến động ngẫu nhiên hoặc sai lệch không mong muốn trong dữ liệu.

Ví dụ: lỗi cảm biến, lỗi nhập liệu.

Giá trị ngoại lệ (Outlier): Là những điểm dữ liệu có giá trị khác biệt đáng kể so với phần lớn dữ liệu.

Phương pháp Trung bình động (MA) - Cách thực hiện: Giá trị mới của một điểm dữ liệu được thay thế bằng Trung bình động của cửa sổ trượt. Trung bình động được tính theo công thức sau:

$$MA_i = \frac{1}{n} \sum_{j=1}^w x_{i-j+1}$$

Trong đó: w : Số lượng phần tử trong cửa sổ làm trơn; x_i : giá trị điểm dữ liệu thứ i .

Ví dụ:

Một cảm biến đo nhiệt độ ghi nhận được 10 giá trị trong một chuỗi thời gian như sau (đơn vị: °C): 25, 26, 30, 38, 36, 100, 38, 40, 42, 39.

Giá trị 100 là giá trị nhiễu. Hãy xử lý giá trị nhiễu theo phương pháp trung bình động ($w=3$).



Phương pháp z-score (Phương pháp ngưỡng chuẩn hóa) dùng để xác định các điểm ngoại lệ (bất thường) của dữ liệu. Giá trị z-score được tính bởi

$$z = \frac{x - \mu}{\sigma}$$

z : z-score của điểm dữ liệu

x : giá trị điểm dữ liệu

μ : trung bình tập dữ liệu

σ : độ lệch chuẩn tập dữ liệu

Giá trị ngoại lệ thường là các điểm có $|z| > 3$ (hoặc tùy theo yêu cầu)



Ví dụ:

Một cửa hàng ghi nhận 10 giá trị doanh thu trong một tuần (đơn vị: triệu đồng) như sau: 22, 20, 22, 25, 23, 80, 25, 21, 77, 25. Hãy xác định các giá trị ngoại lệ với $|z| > 2$.



Tứ phân vị:

$$IQR = Q_3 - Q_1$$

Các giá trị bất thường nằm ngoài khoảng:

$$[Q_1' - 1.5 * IQR, Q_3 + 1.5 * IQR]$$



Ví dụ: Một cửa hàng ghi nhận 10 giá trị doanh thu trong một tuần (đơn vị: triệu đồng) như sau: 22, 20, 22, 25, 23, 80, 25, 21, 77, 25. Xác định giá trị outlier bằng phương pháp IQR.



Giá trị bị thiếu là một vấn đề phổ biến trong các tập dữ liệu thực tế, và việc xử lý chúng là một bước quan trọng trong tiền xử lý dữ liệu. Việc xử lý giá trị bị thiếu có thể ảnh hưởng đến độ chính xác của các mô hình khai thác dữ liệu và phân tích sau này.



Tại sao có các dữ liệu thiếu ?





Cách xử lý dữ liệu thiếu ?



Cách xử lý dữ liệu thiếu:

- 1. Loại bỏ*
- 2. Thay thế: trung bình, trung vị, sử dụng các thuật toán: Linear Regression, kNN, Random forest, ...*



Ví dụ:

Giả sử chúng ta có một tập dữ liệu doanh thu hàng tuần của cửa hàng như sau (đơn vị: triệu đồng):

Dữ liệu gốc: 22, 20, NaN, 25, 23, NaN, 25, 21, 17, 25

Sử dụng phương pháp kNN với $k=2$ để xử lý dữ liệu thiếu.



Phép thống kê cơ bản là một phần quan trọng trong phân tích dữ liệu, giúp chúng ta hiểu rõ hơn về tính chất của dữ liệu. Các phép thống kê này cho phép tóm tắt dữ liệu thành các chỉ số dễ hiểu và rút ra các kết luận quan trọng.

Bao gồm:

1. *Trung bình*
2. *Trung vị*
3. *Yếu vị*
4. *Phương sai*
5. *Độ lệch chuẩn*
6. *Min, Max, Range*

Chia nhóm: Lớp chia thỏa điều kiện

- Số thành viên tối thiểu của nhóm: 4
- Số thành viên tối đa của nhóm: 7
- Nhớ ghi rõ Họ tên + MSSV vào giấy làm bài



Bài tập nhóm:

Giả sử chúng ta có một tập dữ liệu doanh thu hàng tuần của cửa hàng như sau (đơn vị: triệu đồng):

22, 121, NaN, 24, 23, 25, 26, 24, NaN, 122, 23, 24, 28, 25, 17

- 1. Sử dụng phương pháp kNN với $k=2$ để xử lý dữ liệu thiếu.*
- 2. Sử dụng IQR để xác định các giá trị ngoại lệ*
- 3. Áp dụng phương pháp trung bình động để xử lý ngoại lệ ($w = 3$)*