



KHAI THÁC DỮ LIỆU

(KHAI PHÁ DỮ LIỆU)

Buổi 2:

TIỀN XỬ LÝ DỮ LIỆU (tt)



Khái niệm tích hợp dữ liệu: Tích hợp dữ liệu là quá trình kết hợp dữ liệu từ nhiều nguồn khác nhau để tạo ra một tập dữ liệu thống nhất, phù hợp cho mục đích khai thác tri thức hoặc phân tích. Tuy nhiên, dữ liệu từ các nguồn khác nhau có thể chứa mâu thuẫn, dẫn đến sai lệch trong kết quả nếu không được xử lý đúng cách.

Nêu các loại mâu thuẫn có thể có khi tích hợp dữ liệu.



Các loại mâu thuẫn có thể có khi tích hợp dữ liệu:

- Mâu thuẫn giá trị
- Mâu thuẫn định dạng
- Mâu thuẫn logic



Các phương pháp xử lý mâu thuẫn:

- Phương pháp thống nhất giá trị
- Chuẩn hóa định dạng
- Sử dụng các quy tắc logic

Ví dụ: Dữ liệu từ 2 nguồn. Có những mâu thuẫn gì ở đây ? Xử lý như thế nào ?

ID	Tên	Ngày sinh	Doanh thu
1	A. Smith	01-01-1990	500
2	B. Jones	31-12-1989	450

ID	Họ và tên	Ngày sinh	Doanh thu
1	A. Smith	31-12-1989	500
2	B. Jones	31-12-1989	470





Chuẩn hóa dữ liệu nhằm đưa dữ liệu về cùng một thang đo, đặc biệt quan trọng khi các thuộc tính có đơn vị hoặc phạm vi giá trị khác nhau.



Chuẩn hóa giá trị về khoảng [0, 1]

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)}$$

Chuẩn hóa giá trị về khoảng [0, 1]

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)}$$

Ví dụ: Cho dữ liệu [5, 8, 12, 15, 18, 21, 25, 28, 30, 35].
Hãy chuẩn hóa dữ liệu theo phương pháp min-max scale.



Chuẩn hóa giá trị dựa trên trung bình và độ lệch chuẩn

$$x' = \frac{x - \mu}{\sigma}$$

Chuẩn hóa giá trị dựa trên trung bình và độ lệch chuẩn

$$x' = \frac{x - \mu}{\sigma}$$

Ví dụ: Cho dữ liệu [5, 8, 12, 15, 18, 21, 25, 28, 30, 35].
Hãy chuẩn hóa dữ liệu theo phương pháp z-score.



Mỗi giá trị được chia cho độ dài Euclidean của toàn bộ vector

$$x' = \frac{x}{\sqrt{\sum_{i=1}^n x_i^2}}$$

Mỗi giá trị được chia cho độ dài Euclidean của toàn bộ vector

$$x' = \frac{x}{\sqrt{\sum_{i=1}^n x_i^2}}$$

Ví dụ: Cho dữ liệu [5, 8, 12, 15, 18, 21, 25, 28, 30, 35].
Hãy chuẩn hóa dữ liệu theo phương pháp Unit Length.



Làm trơn dữ liệu là quá trình loại bỏ nhiễu để làm nổi bật xu hướng chính trong tập dữ liệu. Phương pháp này thường được sử dụng để chuẩn bị dữ liệu cho các bước phân tích hoặc khai thác tri thức tiếp theo.

Phương pháp trung bình (Mean Smoothing):
Sử dụng trung bình cộng của các giá trị lân cận để thay thế giá trị nhiễu.

$$x'_i = \frac{x_{i-k} + x_{i-k+1} + \dots + x_i + \dots + x_{i+k}}{2k + 1}$$



Ví dụ: Cho dữ liệu [5, 8, 12, 15, 18, 21, 25, 28, 30, 35].
Hãy chuẩn hóa dữ liệu theo phương pháp trung bình
với $k=1$.

Rời rạc hóa là quá trình chuyển đổi dữ liệu liên tục thành các khoảng hoặc các giá trị rời rạc.

Các phương pháp rời rạc hóa

- Equal Width Binning (Phân đoạn chiều rộng bằng nhau)
- Equal Frequency Binning (Phân đoạn tần suất bằng nhau)
- Cluster-Based Discretization (Rời rạc hóa theo cụm)



- Equal Width Binning (Phân đoạn chiều rộng bằng nhau)
- Equal Frequency Binning (Phân đoạn tần suất bằng nhau)



Ví dụ: Cho dữ liệu [5, 8, 12, 15, 18, 21, 25, 28, 30, 35].
Hãy rời rạc hóa bằng phương pháp Equal Width
Binning. Chia thành 4 bin.



Tạo thuộc tính mới là quá trình biến đổi hoặc kết hợp các thuộc tính hiện có trong tập dữ liệu để tạo ra các thuộc tính mới có ý nghĩa hơn, hỗ trợ phân tích hoặc cải thiện hiệu quả của các mô hình học máy.

Các phương pháp tạo thuộc tính mới:

- Kết hợp các thuộc tính hiện có
- Biến đổi hàm toán học
- Tạo thuộc tính từ ngày tháng
- Tạo thuộc tính nhị phân (Binning/Binary Features)

Ví dụ: Cho tập dữ liệu. Hãy:

ID	Age	Salary/Week (triệu đồng)	Working Hours/Week	Work From
1	25	20	40	30/04/2023
2	30	30	45	02/06/2018
3	35	50	38	06/03/2015
4	40	40	50	07/05/2011
5	28	35	42	01/11/2020

- Tạo thuộc tính “Salary per hour” (Lương theo giờ)
- Tạo thuộc tính "Log Salary" (Lấy log cơ số 10 của Lương)
- Tạo thuộc tính “Year Experience” (Năm kinh nghiệm)
- Tạo thuộc tính "Income Level" (=Low nếu Lương < 30, =Medium nếu Lương từ 30 đến 39, =High nếu cao hơn)

Ví dụ: Cho tập dữ liệu.

ID	smoke_fre	num_ciga
1	0	0
2	1	12
3	2	8
4	3	5
5	4	4
6	5	3
7	6	2
8	7	1
9	3	6
10	2	10

Trong đó, smoke_fre: tần số hút thuốc

- 0: không hút
- 1: hút hàng ngày
- 2: 1 tuần 3 lần
- 3: 1 tuần 2 lần
- 4: 1 tuần 1 lần
- 5: 1 tháng 2 lần
- 6: 1 tháng 1 lần
- 7: có hút nhưng ít hơn 1 tháng 1 lần

Tạo thuộc tính num_ciga_per_month: Thể hiện số điếu thuốc hút trong 1 tháng



Chia nhóm: Lớp chia thỏa điều kiện

- Tổng số nhóm: 10
- Số thành viên tối thiểu của nhóm: 5
- Nhớ ghi rõ Họ tên + MSSV vào giấy làm bài

Một công ty ghi nhận thông tin về khách hàng và giao dịch qua bảng dữ liệu dưới đây.

ID	Age	Gender	Income (\$)	Transactions	Spend (\$)	Membership	JoinYear
C001	25	Male	50000	15	3000	Gold	2019
C002	34	Female	60000	20	4000	Gold	2018
C003	29	Male	40000	12	NaN	Silver	2020
C004	NaN	Female	55000	18	3700	Silver	2019
C005	45	Female	NaN	25	4500	Gold	2015
C006	32	Male	200000	50	20000	Platinum	2017
C007	-1	Male	42000	NaN	3800	Silver	2019
C008	30	Male	52000	14	3200	Silver	2019
C009	27	Other	60000	22	5000	Gold	2018
C010	35	Female	55000	18	-3000	Silver	2019

- Thực hiện xử lý các giá trị thiếu. Phát hiện và xử lý các giá trị mâu thuẫn.
- Làm trơn dữ liệu bằng phương pháp trung bình ($k=2$) với cột Spend và Transactions.
- Chuẩn hóa dữ liệu với min-max scaling cho Spend và Income