



KHAI THÁC DỮ LIỆU (KHAI PHÁ DỮ LIỆU)

Buổi 3:

KHAI THÁC TẬP PHỔ BIẾN – APRIORI



Một siêu thị lưu hàng triệu hóa đơn trong nhiều năm.
Như vậy, từ toàn bộ dữ liệu đó chúng ta có thể tìm ra
những “quy luật” hoặc “mẫu” gì có ích?



Định nghĩa Pattern Mining

- Pattern Mining (khai thác mẫu) là một nhánh quan trọng trong khai thác dữ liệu, tập trung vào việc phát hiện các mẫu có ý nghĩa từ tập dữ liệu lớn. Các mẫu có thể là tập hợp các mục thường xuất hiện cùng nhau, chuỗi sự kiện, cây hoặc đồ thị có cấu trúc đặc biệt.

Nếu “mẫu” trong dữ liệu không chỉ là các sản phẩm xuất hiện cùng nhau, thì mẫu còn có thể mang những hình thức nào khác?



Frequent Pattern Mining (Khai thác tập phổ biến)

- Frequent Pattern Mining là quá trình tìm kiếm các tập hợp mục (itemset), chuỗi (sequence) hoặc cấu trúc (structure) xuất hiện với tần suất lớn hơn một ngưỡng tối thiểu (min-support) trong dữ liệu. Mục tiêu là phát hiện các mẫu phổ biến để hỗ trợ ra quyết định trong nhiều lĩnh vực như kinh doanh, y tế và an ninh.

Frequent Pattern Mining (Khai thác tập phổ biến) – Ví dụ

Siêu thị muốn biết những sản phẩm nào thường được mua cùng nhau để tối ưu sắp xếp kệ hàng.

Dữ liệu giao dịch

Giao dịch 1: {Sữa, Bánh mì, Bơ}

Giao dịch 2: {Sữa, Bánh mì}

Giao dịch 3: {Bánh mì, Nước ngọt}

Giao dịch 4: {Sữa, Bánh mì, Nước ngọt}

Nếu hệ thống phát hiện rằng **Sữa và Bánh mì** xuất hiện cùng nhau trong **3/4 giao dịch**, có thể sắp xếp hai sản phẩm này gần nhau để tăng doanh số.

Sequential Pattern Mining (Khai thác mẫu tuần tự)


- Sequential Pattern Mining tìm kiếm các mẫu xuất hiện theo trình tự thời gian trong một tập dữ liệu. Mỗi mẫu tuần tự thể hiện một chuỗi các sự kiện hoặc hành động liên tiếp, giúp phân tích hành vi khách hàng, chuỗi sự kiện trong y tế hoặc nghiên cứu dữ liệu sinh học.

Sequential Pattern Mining (Khai thác mẫu tuần tự) - VD

- Website thương mại điện tử muốn tìm hiểu hành vi khách hàng khi mua sắm online.
- Dữ liệu được thu thập dưới dạng chuỗi các sự kiện
 - Người dùng 1: (Tìm kiếm điện thoại) → (Xem đánh giá) → (Thêm vào giỏ hàng)
 - Người dùng 2: (Tìm kiếm điện thoại) → (Xem đánh giá) → (Thoát trang)
 - Người dùng 3: (Tìm kiếm điện thoại) → (Thêm vào giỏ hàng) → (Thanh toán)
- Phát hiện rằng hơn 60% người dùng xem đánh giá sau khi tìm kiếm điện thoại, cửa hàng có thể cải thiện trải nghiệm bằng cách đề xuất đánh giá ngay bên dưới sản phẩm.

Subgraph Pattern Mining (Khai thác mẫu đồ thị)

- Subgraph Pattern Mining tập trung vào việc phát hiện các mẫu đồ thị con có ý nghĩa trong dữ liệu đồ thị. Dạng khai thác này thường được ứng dụng trong phân tích mạng xã hội, nghiên cứu hóa học và an ninh mạng.



Subgraph Pattern Mining (Khai thác mẫu đồ thị) - VD

- Facebook muốn phát hiện các nhóm người thường xuyên tương tác với nhau để đề xuất kết bạn.
- Nếu có một nhóm người dùng **A, B, C, D** thường xuyên tương tác qua bình luận và nhắn tin, thuật toán có thể xác định họ là một cộng đồng và đề xuất họ kết bạn với những người có chung sở thích.

High Utility Pattern Mining (Khai thác mẫu có lợi ích cao)

- Không chỉ xét tần suất xuất hiện, High Utility Pattern Mining còn đánh giá giá trị kinh tế hoặc trọng số của từng mục để tìm ra các mẫu có lợi ích cao. Điều này giúp tối ưu hóa chiến lược kinh doanh và quản lý tài nguyên hiệu quả.

High Utility Pattern Mining – Ví dụ

- Một cửa hàng bán lẻ muốn tìm ra những sản phẩm có doanh thu cao, không chỉ dựa vào tần suất xuất hiện.
- Dữ liệu giao dịch
 - Giao dịch 1: {Sản phẩm A - 500\$, Sản phẩm B - 20\$, Sản phẩm C - 5\$}
 - Giao dịch 2: {Sản phẩm A - 500\$, Sản phẩm C - 5\$}
 - Giao dịch 3: {Sản phẩm B - 20\$, Sản phẩm C - 5\$} ...

Phát hiện rằng **Sản phẩm A** xuất hiện ít nhưng đóng góp **70% tổng doanh thu**, cửa hàng có thể tập trung chiến lược quảng bá vào sản phẩm này.

Rare Pattern Mining (Khai thác tập không phổ biến)

- Rare Pattern Mining tập trung vào các mẫu có tần suất xuất hiện thấp nhưng vẫn có giá trị quan trọng, đặc biệt trong các lĩnh vực như phát hiện gian lận, chẩn đoán bệnh hiếm và bảo mật thông tin.

Rare Pattern Mining – Ví dụ

- Ngân hàng muốn phát hiện giao dịch bất thường để ngăn chặn gian lận.
- Dữ liệu giao dịch của 1 khách hàng qua từng ngày
 - {Chuyển khoản 10 triệu, Thanh toán hóa đơn 2 triệu, Mua hàng online 1 triệu}
 - {Chuyển khoản 15 triệu, Thanh toán hóa đơn 3 triệu, Mua hàng online 2 triệu}
 - {Chuyển khoản 500 triệu, Thanh toán hóa đơn 2 triệu, Mua hàng online 1 triệu}

Phát hiện rằng **99% giao dịch thường dưới 50 triệu, nhưng có một giao dịch 500 triệu**, hệ thống có thể tự động cảnh báo và yêu cầu xác minh.

Giả sử chúng ta chỉ quan tâm đến các sản phẩm thường xuất hiện cùng nhau trong hóa đơn. Như vậy, dữ liệu phải được biểu diễn như thế nào để máy tính có thể đếm được một nhóm sản phẩm xuất hiện bao nhiêu lần?



Tập dữ liệu giao dịch

Một tập dữ liệu giao dịch (transaction database) là tập hợp các giao dịch, mỗi giao dịch là một tập hợp các hạng mục (itemset).

- Gọi $I = \{i_1, i_2, \dots, i_n\}$ là tập hợp tất cả các hạng mục (items).
- Gọi $D = \{T_1, T_2, \dots, T_m\}$ là tập giao dịch, trong đó $T_i \subseteq I$

Tập dữ liệu giao dịch

Một tập dữ liệu giao dịch (transaction database) là tập hợp các giao dịch, mỗi giao dịch là một tập hợp các hạng mục (itemset).

Ví dụ

Transaction ID	Items
T1	{Milk, Bread, Butter}
T2	{Milk, Bread}
T3	{Bread, Butter}
T4	{Milk, Bread, Butter, Jam}
T5	{Bread, Jam}

Itemset và Support

Itemset: Một tập hợp con các hạng mục trong I .

Hỗ trợ (Support) của một itemset X là số lượng giao dịch trong D chứa X , ký hiệu $sup(X)$

$$sup(X) = \frac{\text{số giao dịch chứa } X}{\text{tổng số giao dịch}}$$

Itemset và Support

VD: Tính support của **{Milk, Bread}**

Transaction ID	Items
T1	{Milk, Bread, Butter}
T2	{Milk, Bread}
T3	{Bread, Butter}
T4	{Milk, Bread, Butter, Jam}
T5	{Bread, Jam}

Ngưỡng tối thiểu (minsup) và tập phổ biến

Ngưỡng hỗ trợ tối thiểu (minsup): Giá trị ngưỡng do người dùng đặt để xác định tập phổ biến.

Tập phổ biến (Frequent Itemset, FI): Itemset có *support* $\geq$ *minsup*

Ngưỡng tối thiểu (minsup) và tập phổ biến

VD: tập {Milk, Bread}, {Bread, Butter}, {Jam}

Transaction ID	Items
T1	{Milk, Bread, Butter}
T2	{Milk, Bread}
T3	{Bread, Butter}
T4	{Milk, Bread, Butter, Jam}
T5	{Bread, Jam}

Ví dụ, minsup = 0.6

Transaction ID	Items
T1	{A, B, C}
T2	{A, C}
T3	{A, B}
T4	{B, C}
T5	{A, B, C}

Tính support của các itemset

itemset	support
{A}	
{B}	
{C}	

Ví dụ, minsup = 0.6

Transaction ID	Items
T1	{A, B, C}
T2	{A, C}
T3	{A, B}
T4	{B, C}
T5	{A, B, C}

Tính support của các itemset

itemset	support
{A, B}	
{B, C}	
{A, C}	

Ví dụ, $\text{minsup} = 0.6$

Transaction ID	Items
T1	{A, B, C}
T2	{A, C}
T3	{A, B}
T4	{B, C}
T5	{A, B, C}

Tính support của các itemset

itemset	support
{A, B, C}	

Nếu một nhóm sản phẩm $\{A, B\}$ đã xuất hiện quá ít để đạt minsup, liệu có cần tiếp tục kiểm tra $\{A, B, C\}$, $\{A, B, D\}$, $\{A, B, C, D\}$... hay không? Vì sao?





Thuật toán Apriori là một trong những thuật toán phổ biến nhất trong khai thác tập phổ biến (**Frequent Itemset Mining**). Thuật toán này sử dụng tính chất **Apriori Property** để cắt giảm không gian tìm kiếm, giúp tối ưu quá trình tìm các tập phổ biến.

Nguyên lý Apriori (Apriori Property)

Nếu một itemset là phổ biến, thì tất cả các tập con của nó cũng phải phổ biến.

Ví dụ: Nếu $\{A, B, C\}$ là phổ biến, thì $\{A, B\}$, $\{A, C\}$ và $\{B, C\}$ cũng phải phổ biến.

Nguyên lý Apriori (Apriori Property)

Nếu một itemset là phổ biến, thì tất cả các tập con của nó cũng phải phổ biến.

Ví dụ: Nếu $\{A, B, C\}$ là phổ biến, thì $\{A, B\}$, $\{A, C\}$ và $\{B, C\}$ cũng phải phổ biến.

Hệ quả: Nếu một tập con không phổ biến, thì mọi tập cha chứa nó cũng không phổ biến. Điều này giúp giảm số lượng tập ứng viên cần kiểm tra.

Các bước chính của thuật toán

Gọi C_k là các tập có k hạng mục. Thuật toán thực hiện như sau:

- Khởi tạo $k = 1$. Gọi F là tập hợp các tập phổ biến. $F = \emptyset$
- Bước 1: Đếm độ hỗ trợ của từng tập trong C_k
- Bước 2: Loại bỏ các ứng viên C_k không phổ biến.
- Bước 3: Thêm các tập C_k thỏa ngưỡng minsup vào F .
- Bước 4: Phát sinh ứng viên C_{k+1} dựa trên các F_k
- Bước 5: Tăng k và lặp lại cho đến khi tất cả tập phổ biến được phát sinh.

Ví dụ: Cho CSDL giao tác như sau. Tìm tất cả tập phổ biến thỏa ngưỡng $\text{minsup} = 50\%$ ($\text{supcount} \geq 3$)

TID	Items
1	A, C, T, W
2	C, D, W
3	A, C, T, W
4	A, C, D, W
5	A, C, D, T, W
6	C, D, T

C_1	Support
A	
C	
D	
T	
W	

Ví dụ: Cho CSDL giao tác như sau. Tìm tất cả tập phổ biến thỏa ngưỡng $\text{minsup} = 50\%$ ($\text{supcount} \geq 3$)

TID	Items
1	A, C, T, W
2	C, D, W
3	A, C, T, W
4	A, C, D, W
5	A, C, D, T, W
6	C, D, T

C_1	Support
A	4
C	6
D	4
T	4
W	5



F_1	Support
A	4
C	6
D	4
T	4
W	5

TID	Items
1	A, C, T, W
2	C, D, W
3	A, C, T, W
4	A, C, D, W
5	A, C, D, T, W
6	C, D, T

C2	Support Count
A, C	
A, D	
A, T	
A, W	
C, D	
C, T	
C, W	
D, T	
D, W	
T, W	

C ₂	Support
A,C	4
A,D	2
A,T	3
A,W	4
C,D	4
C,T	4
C,W	5
D,T	2
D,W	3
T,W	3



F ₂	Support
A,C	4
A,T	3
A,W	4
C,D	4
C,T	4
C,W	5
D,W	3
T,W	3

TID	Items
1	A, C, T, W
2	C, D, W
3	A, C, T, W
4	A, C, D, W
5	A, C, D, T, W
6	C, D, T

F_2	Support
A,C	4
A,T	3
A,W	4
C,D	4
C,T	4
C,W	5
D,W	3
T,W	3



C_3	Support

C ₂	Support
A,C	4
A,D	2
A,T	3
A,W	4
C,D	4
C,T	4
C,W	5
D,T	2
D,W	3
T,W	3



F ₂	Support
A,C	4
A,T	3
A,W	4
C,D	4
C,T	4
C,W	5
D,W	3
T,W	3



C ₃	Support
A,C,W	4
A,C,D	2
A,C,T	3
A,T,W	3
C,D,T	2
C,D,W	3
C,T,W	3



Tập con không phổ biến

F_3	Support
A,C,W	4
A,C,T	3
A,T,W	3
C,D,W	3
C,T,W	3



C_4	Support
A,C,T,W	3
C,D,T,W	1



F_4	Support
A,C,T,W	4

Kết quả: Có tất cả bao nhiêu tập phổ biến ?



F_3	Support
A,C,W	4
A,C,T	3
A,T,W	3
C,D,W	3
C,T,W	3



C_4	Support
A,C,T,W	3
C,D,T,W	1



F_4	Support
A,C,T,W	4

Như vậy có tất cả 19 tập phổ biến thỏa minsup = 50%

Chú ý quan trọng về BTVN Số 3:

- BTVN số 3 không làm trắc nghiệm.
- Sinh viên thực hiện trên giấy, chụp hình và đăng Facebook cá nhân ở ***chế độ công khai***. Không công khai thầy không có đọc được đâu mà chấm.
- Cuối cùng nộp link vào classroom.
- Đừng xóa bài cho đến khi có điểm. Để đó còn chấm chứ.
- Xem chi tiết đề trên Classroom.

Chia nhóm: Lớp chia thỏa điều kiện

- Số thành viên của nhóm: 3 - 8
- Số thành viên của nhóm nhiều nhất và nhóm ít nhất không vượt quá 2
- Nhớ ghi rõ Họ tên + MSSV vào giấy làm bài

VD: Tìm các tập phổ biến minsup = 0.3 trong CSDL sau

Transaction ID	Items
T1	{A, B, D, E}
T2	{B, C, E}
T3	{A, B, C, E}
T4	{B, E}
T5	{A, B, C, D}
T6	{B, C}
T7	{A, C, D, E}
T8	{A, B, C}
T9	{A, C, D}
T10	{B, C, D}