



KHAI THÁC DỮ LIỆU (DATAMINING)

Khoa CNTT



NỘI DUNG MÔN HỌC

Chương 1. Tổng quan về khai thác dữ liệu

Chương 2. Tiền xử lý dữ liệu

Chương 3: Tập phổ biến

Chương 4: Luật kết hợp

Chương 5. Phân lớp dữ liệu

Chương 6. Gom cụm dữ liệu



TÀI LIỆU THAM KHẢO

- [1] Đỗ Phúc, Khai phá dữ liệu, NXB ĐHQG TP.HCM, 2022.
- [2] Trần Minh Quang, Khai phá dữ liệu và kỹ thuật phân lớp, NXB Đại học quốc gia TP.Hồ Chí Minh, 2020
- [3] Jiawei Han, Jian Pei, Hanghang Tong, *Data Mining Concepts and Techniques*, Fourth Edition, Morgan Kaufmann, Elsevier, 2023.



Google classroom

Zalo:



CHƯƠNG 1

Tổng quan về khai thác dữ liệu




NỘI DUNG CHƯƠNG 1

- Mở đầu
- Sự đa dạng của các kiểu dữ liệu
- Các công đoạn khám phá tri thức từ CSDL
- Ứng dụng của KTDL
- Khái quát các kỹ thuật khai thác dữ liệu
- Những thách thức trong khai thác dữ liệu



SỰ GIA TĂNG DỮ LIỆU





DỮ LIỆU BIỂU DIỄN

Attributes

Objects

U	Đau đầu	Đau cơ	Thân nhiệt	Cảm cúm
u1	Có	Có	Bình thường	Không
u2	Có	Có	Cao	Có
u3	Có	Có	Rất cao	Có
u4	Không	Có	Bình thường	Không
u5	Không	Không	Cao	Không
u6	Không	Có	Rất cao	Có



DỮ LIỆU BIỂU DIỄN

<i>TID</i>	<i>Items</i>
1	Bread, Coke, Milk
2	Beer, Bread
3	Beer, Coke, Diaper, Milk
4	Beer, Bread, Diaper, Milk
5	Coke, Diaper, Milk



DỮ LIỆU BIỂU DIỄN-chuỗi tg




Yahoo Finance Website



DỮ LIỆU BIỂU DIỄN-khoảng tg

$EL = \{ (A, 1, 5), (C, 3, 12), (B, 4, 9), (D, 9, 15) \}$




$((A \text{ overlaps } C) \text{ *contains* } B) \text{ *overlaps* } D)$






DỮ LIỆU BIỂU DIỄN-k³ gian



Average Monthly Temperature of land and ocean




DỮ LIỆU BIỂU DIỄN-k_g gian







DỮ LIỆU BIỂU DIỄN-di chuyển



DỮ LIỆU BIỂU DIỄN-đồ thị



DỮ LIỆU BIỂU DIỄN-cấu trúc





DỮ LIỆU BIỂU DIỄN-phi cấu trúc



Jason Y.
Reviews
Written: 69



09/22/2006

Excellent Vietnamese restaurant. Some of my favorites are the sour salmon soup, vietnamese steak, summer rolls, and orange chicken. The tofu w/ginger and scallion special is good. I prefer the pho at pho-specific places. they don't give you basil or chilies with the pho here.

[Bookmark](#) [Send to a Friend](#)



Aaron E.
Reviews
Written: 75



01/18/2006

They have great fried spring rolls and fresh garden rolls. However, for \$3.50 2 smallish rolls doesn't seem that great. They make up for this with a large bowl of Pho soup for around \$6.00. This place is great for food just before you see a movie at the Uptown theater. However, leave plenty of time. When the place is busy, the waitstaff or kitchen starts to suck and get real slow. You will miss your movie. Give yourself 1.5 hours before a movie start time. This PHO place is not as ghetto as other PHO places (like PHO 75).

[Bookmark](#) [Send to a Friend](#)



Sean G.
Reviews
Written: 126



03/06/2006

The pho is good -- esp for DC -- but not great compared to some of the Pho joints in Seattle who can drop a bowl of broth and noodles that will blow your mind for under \$4 bucks. Travelling... the downside is you learn what youre missing.... That said, this is a decent spot for a late lunch over a hot bowl of the the good stuff.

[Bookmark](#) [Send to a Friend](#)



Nils J.
Reviews
Written: 76




04/14/2006

Good pho, reasonable prices, and great for eating dinner before you go to the Uptown for a flick. The wait staff can be very unresponsive, though, which is annoying. Unfortunately, they don't give you basil and cilantro along with the sprouts to dump into your pho.

[Bookmark](#) [Send to a Friend](#)



DỮ LIỆU BIỂU DIỄN-đa chiều





Ý NGHĨA KHAI PHÁ DỮ LIỆU

- ❑ Rất nhiều dữ liệu cần được thu thập và lưu trữ
 - Dữ liệu web
 - Yahoo có hàng PetaByte (triệu gigabyte) dữ liệu web
 - Facebook có hàng tỷ người dùng
 - Thương mại điện tử
 - Amazon xử lý hàng triệu lượt truy cập mỗi ngày
 - Giao dịch ngân hàng, thẻ tín dụng
- ❑ Máy tính đã trở nên rẻ hơn và mạnh hơn
- ❑ Áp lực cạnh tranh mạnh mẽ
 - Cung cấp dịch vụ tốt hơn (ví dụ như việc quản lý mối quan hệ khách hàng)



Ý NGHĨA KHAI PHÁ DỮ LIỆU

❑ Dữ liệu sưu tập và lưu trữ đang được gia tăng nhanh chóng

- Cảm biến từ xa trên vệ tinh
 - NASA lưu trữ hàng petabytes về khoa học trái đất mỗi năm
- Kính viễn vọng quét bầu trời
 - Dữ liệu khảo sát bầu trời
- Dữ liệu công nghệ sinh học
- Mô phỏng khoa học
 - Hàng terabyte (nghìn gigabyte) dữ liệu được tạo ra trong một vài giờ

→ Khai phá dữ liệu giúp khoa học trong việc

- Phân tích tự động các bộ dữ liệu lớn
- Hình thành giả thuyết



Ý NGHĨA KHAI PHÁ DỮ LIỆU




**Cải thiện chăm sóc sức khỏe
và giảm chi phí**



**Tìm nguồn năng lượng xanh
để thay thế**

CCSm/A2a January to January Mean Temperature (degrees C) 2080s relative to 1961-90




Dự báo về biến đổi khí hậu






**Giảm đói nghèo bằng cách
tăng gia sản xuất nông nghiệp**

Ý NGHĨA KHAI PHÁ DỮ LIỆU



Average Monthly Temperature of land and ocean






KHÁM PHÁ TRI THỨC

1. Khám phá tri thức

- Khám phá tri thức từ CSDL (*KDD - Knowledge Discovery in Database*) là quá trình tìm ra những tri thức, đó là những mẫu tin tiềm ẩn (mẫu có ích), trước đó chưa biết và là thông tin hữu ích đáng tin cậy trong một tập dữ liệu khổng lồ và phức tạp.

KHÁM PHÁ TRI THỨC

2. Các bước KDD





KHÁM PHÁ TRI THỨC

Bước 1: Chọn dữ liệu: Lựa chọn DL phù hợp với nhiệm vụ phân tích.

Xác định nhiệm vụ cần nghiên cứu sử dụng Data mining để rút ra được những tri thức cần chất lọc, từ đó định hướng để tránh tốn thời gian cho những tri thức không cần thiết.



KHÁM PHÁ TRI THỨC

Bước 2: Tiền xử lý: Làm sạch và chuẩn bị trước DL, xử lý các dữ liệu không chắc chắn, dữ liệu nhiễu.

Đây là giai đoạn quan trọng vì dữ liệu nếu không chính xác sẽ gây kết quả sai lệch nghiêm trọng.



KHÁM PHÁ TRI THỨC

Bước 3: Chuyển đổi dữ liệu: dữ liệu được chuyển đổi hay được tích hợp về dạng thích hợp cho việc khai thác.

Bước 4: Khai thác dữ liệu: Đây là tiến trình cốt yếu, nhiều thuật toán khác nhau được sử dụng để trích xuất thông tin có ích hoặc các mẫu điển hình trong DL.



KHÁM PHÁ TRI THỨC

Bước 5: Đánh giá kết quả mẫu: kiểm tra, đánh giá để trích xuất ra các tri thức cần thiết.




KHAI PHÁ DỮ LIỆU LÀ GÌ

Khai phá dữ liệu:

Là một quá trình trích xuất tri thức (thông tin tiềm ẩn hữu ích) từ lượng dữ liệu lớn.



NGUỒN GỐC KHAI PHÁ DỮ LIỆU






NGUỒN GỐC KHAI PHÁ DỮ LIỆU

Nguyên nhân các kỹ thuật truyền thống không còn phù hợp:

- Số lượng dữ liệu lớn
- Nhiều chiều
- Không đồng nhất
- Dữ liệu phức tạp

ỨNG DỤNG KHAI PHÁ DỮ LIỆU



Clustering



Data

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes
11	No	Married	60K	No
12	Yes	Divorced	220K	No
13	No	Single	85K	Yes
14	No	Married	75K	No
15	No	Single	90K	Yes

Predictive Modeling

Association Rules

Anomaly Detection






Các phương pháp, kỹ thuật trong KTDL

Phân lớp – Classification

<i>Tid</i>	Employed	Level of Education	# years at present address	Credit Worthy
1	Yes	Graduate	5	Yes
2	Yes	High School	2	No
3	No	Undergrad	1	No
4	Yes	High School	10	Yes
...	...	...	...	...

Mô hình dự báo tín dụng





Các phương pháp, kỹ thuật trong KTDL

Phân lớp – Classification

Phân lớp là quá trình gán nhãn cho các mẫu dữ liệu mới với độ chính xác có thể.

Cho CSDL $D = \{t_1, t_2, \dots, t_n\}$ và tập các lớp $C = \{c_1, c_2, \dots, c_m\}$, phân lớp là bài toán xác định ánh xạ $f: D \rightarrow C$ sao cho mỗi t_i được gán vào một lớp c_j .



Các phương pháp, kỹ thuật trong KTDL


Ứng dụng Phân lớp – Classification:

- Phân loại thể tín dụng là hợp pháp hoặc lừa đảo.
- Phân loại độ che phủ đất (thủy vực, đô thị, rừng...) bằng dữ liệu vệ tinh.
- Phân loại các tin tức như tài chính, thời tiết, giải trí, thể thao...
- Xác nhận kẻ xâm nhập không gian mạng.
- Dự báo tế bào khối u lành tính hay ác tính.



Các phương pháp, kỹ thuật trong KTDL

Gom cụm – Clustering





Các phương pháp, kỹ thuật trong KTDL

Gom các
hình sau
thành 3
nhóm





Các phương pháp, kỹ thuật trong KTDL

Có bao
nhiều
nhóm các
hình
trong ảnh





Các phương pháp, kỹ thuật trong KTDL

Gom cụm – Clustering

Phân cụm (clustering) là quá trình nhóm/tập hợp các đối tượng thành những nhóm/cụm/lớp sao cho:

- Các đối tượng cùng cụm có độ tương tự cao.
- Và rất khác với đối tượng ở các cụm còn lại.



Các phương pháp, kỹ thuật trong KTDL

Ứng dụng gom cụm:

- Tùy chỉnh hồ sơ cho mục tiêu tiếp thị.
- Nhóm các tài liệu liên quan để duyệt.
- Nhóm cổ phiếu có biến động giá tương tự
- Giảm kích thước của tập dữ liệu lớn.



Các phương pháp, kỹ thuật trong KTDL

Luật kết hợp

<i>TID</i>	<i>Items</i>
1	Bread, Coke, Milk
2	Beer, Bread
3	Beer, Coke, Diaper, Milk
4	Beer, Bread, Diaper, Milk
5	Coke, Diaper, Milk

Các luật được khai phá:

$\{\text{Milk}\} \rightarrow \{\text{Coke}\}$

$\{\text{Diaper, Milk}\} \rightarrow \{\text{Beer}\}$



Các phương pháp, kỹ thuật trong KTDL

Luật kết hợp

Cho một tập mẫu tin, mỗi mẫu tin chứa các phần tử trong một bộ sưu tập cho trước.

- Tạo ra các luật phụ thuộc nhằm dự báo sự xuất hiện của một phần tử dựa trên sự xuất hiện của các phần tử khác.



Các phương pháp, kỹ thuật trong KTDL

Ứng dụng luật kết hợp:

Phân tích thị trường

- Những luật được sử dụng cho quảng cáo bán hàng, quản lý hàng tồn kho...

Dự đoán báo động viễn thông

- Những luật được sử dụng để tìm sự kết hợp của các báo động xảy ra cùng nhau thường xuyên trong cùng khoảng thời gian.

Tin học – Y khoa

- Những luật được sử dụng để tìm sự kết hợp của các triệu chứng của bệnh nhân và kết quả xét nghiệm liên quan đến một số bệnh.



Những thách thức trong KTDL

KTDL làm việc với khối lượng dữ liệu lớn từ nhiều nguồn khác nhau (internet, các loại thiết bị nhận dạng, thu nhận tín hiệu, ...) -> tốc độ xử lý là vấn đề cần quan tâm.

Hai hướng giải quyết:

- +Nâng cao năng lực của phần cứng

- +Cải tiến phần mềm: đề xuất các giải thuật hiệu quả trên khối dữ liệu lớn, độ phức tạp tính toán thấp là hướng nghiên cứu tiềm năng.

Các ngành KH-CN hỗ trợ: tính toán song song, tính toán phân tán, ...



Môi trường thử nghiệm - Weka



Chim Weka: Sinh sống ở New Zealand



Môi trường thử nghiệm - Weka

