



TIỀN XỬ LÝ DỮ LIỆU



Học có giám sát và học không giám sát

Mushroom cap shapes



convex



bell-shaped



conical



knobbed




flat



sunken

Mushroom cap surfaces




smooth



velvety



hairy or fibrous



raised scales




flat scales



patches


Annular rings




pendant



flaring




sheathing



double



cobwebby



ring zone

Phân loại:
Không có độc
hoặc Có độc?



Học có giám sát và học không giám sát

Học có giám sát – supervised learning:

Ví dụ:

- Dự đoán giới tính (M, F) từ cân nặng và chiều cao
- Dự báo lứa tuổi trưởng thành (A), vị thành niên (J) từ cân nặng và chiều cao



Học có giám sát và học không giám sát

Học có giám sát – supervised learning:

- Là một phương pháp của ngành học máy nhằm tìm ra một mô hình phù hợp với các quan sát.
- Thuật toán dự đoán đầu ra (outcome) của một dữ liệu mới (new input) dựa trên các cặp (input, outcome) đã biết từ trước. Cặp dữ liệu này còn được gọi là (data, label) – dữ liệu huấn luyện.



Học có giám sát và học không giám sát

Học có giám sát - supervised learning:

- Biểu diễn toán học: ($\{X, Y\}$ là cặp {data, label}) ban đầu với:
 $X = \{x_1, x_2, \dots, x_N\}$ và $Y = \{y_1, y_2, \dots, y_N\}$ là các cặp dữ liệu biết trước $(x_i, y_i) \in X \times Y$ được gọi là tập *training data*. Tìm một hàm ánh xạ $Y = f(X)$, mỗi phần tử từ tập X_x sang một phần tử tương ứng của tập Y_y . Khi có dữ liệu X_i mới máy sẽ tính được Y_i tương ứng dựa vào hàm f .
- Học có giám sát còn được chia nhỏ thành: Phân lớp và hồi qui.



Học có giám sát và học không giám sát


Ví dụ học có giám sát:

- Trong nhận dạng chữ viết tay, từ ảnh của hàng nghìn ví dụ của mỗi chữ số được viết bởi nhiều người khác nhau. Chúng ta đưa các bức ảnh này vào trong một thuật toán và chỉ cho nó biết mỗi bức ảnh tương ứng với chữ số nào. Sau khi thuật toán tạo ra một mô hình, tức một hàm số mà đầu vào là một bức ảnh và đầu ra là một chữ số, khi nhận được một bức ảnh mới mà mô hình **chưa nhìn thấy bao giờ**, nó sẽ dự đoán bức ảnh đó chứa chữ số nào.



Học có giám sát và học không giám sát

Học không giám sát – unsupervised learning:





Học có giám sát và học không giám sát

Học không giám sát - unsupervised learning:

- Là một phương pháp của ngành học máy nhằm tìm ra một mô hình phù hợp với các quan sát.
- Nhãn lớp của tập huấn luyện không biết trước. Trong thuật toán này, chúng ta không biết được outcome hay nhãn mà chỉ có dữ liệu đầu vào. Thuật toán unsupervised learning sẽ dựa vào cấu trúc của dữ liệu để thực hiện một công việc nào đó để thuận tiện trong việc lưu trữ và tính toán.
- Học không giám sát còn được chia nhỏ thành: Gom nhóm và kết hợp.



Học có giám sát và học không giám sát

Ví dụ học không giám sát:

- Khi quan sát một nhóm nhiều người nhưng chưa có thông tin về họ. Dựa vào các đặc điểm như: gương mặt, cách ăn nói, trang phục hay phong thái ... Từ đó có thể phân chia thành các nhóm theo: trình độ học vấn, nghề nghiệp, tuổi ... (hoặc có thể chia ra nhiều nhóm hơn)



Các kỹ thuật tiền xử lý dữ liệu

Tiền xử lý dữ liệu là gì?


- Là quá trình xử lý dữ liệu thô/gốc ban đầu nhằm cải thiện chất lượng dữ liệu → cải thiện chất lượng của kết quả khai thác.
- Dữ liệu thô/gốc:
 - Có cấu trúc, bán cấu trúc, phi cấu trúc;
 - Được đưa vào từ các nguồn khác nhau.

Các kỹ thuật tiền xử lý dữ liệu

1. Làm sạch dữ liệu – Data cleaning

- Là quá trình xử lý các giá trị thiếu, xác định và loại bỏ dữ liệu sai biệt, dữ liệu nhiễu và giải quyết dữ liệu mâu thuẫn.

Data cleaning






Các kỹ thuật tiền xử lý dữ liệu

2. Tích hợp dữ liệu – Data integration

- Tổng hợp, tích hợp dữ liệu từ nhiều CSDL, tập tin dữ liệu khác nhau.

Data integration





Các kỹ thuật tiền xử lý dữ liệu

3. Biến đổi dữ liệu – Data transformation

- Chuẩn hoá và tổng hợp dữ liệu


Data transformation $-2, 32, 100, 59, 48 \longrightarrow -0.02, 0.32, 1.00, 0.59, 0.48$



Các kỹ thuật tiền xử lý dữ liệu

4. Thu giảm dữ liệu – Data reduction

- Giảm kích thước dữ liệu nhưng đảm bảo kết quả phân tích.
- Bằng cách kết hợp dữ liệu, loại bỏ các đặc điểm dư thừa, gom cụm dữ liệu.





Làm sạch dữ liệu

Là quá trình xử lý các giá trị thiếu, loại bỏ dữ liệu sai biệt, dữ liệu nhiễu và giải quyết dữ liệu mâu thuẫn.

Dữ liệu thiếu:

- **Bỏ qua các mẫu tin có giá trị bị thiếu:** Phương pháp này dễ nhưng không hiệu quả đặc biệt khi tỉ lệ giá trị thiếu của trường nào đó cao.
- **Điền vào các giá trị thiếu bằng tay:** Phương pháp này thường tốn thời gian và có thể không khả thi cho một tập dữ liệu nguồn lớn với nhiều giá trị bị thiếu.
- **Điền giá trị thiếu tự động:** Thay thế bằng giá trị trung bình của thuộc tính, thay thế bằng giá trị có nhiều khả năng nhất.



Làm sạch dữ liệu

Dữ liệu nhiễu

- Nhiễu dữ liệu là một lỗi ngẫu nhiên hoặc sự ghi chép nhầm lẫn không được kiểm soát.
- Dùng các phương pháp đo lường sự tập trung của dữ liệu → xử lý nhiễu như: chia giỏ, hồi qui, gom cụm.



Làm sạch dữ liệu

Chống trùng lặp: xóa bỏ thông tin trùng của các bản ghi

Nguyên nhân:

- Sai sót trong phần nhập dữ liệu
- Thông tin không được cập nhật kịp thời
- Thông tin được cung cấp bị sai

...



Làm sạch dữ liệu

Ví dụ:

Bảng 1.3: Bảng kết quả thu thập dữ liệu

Makh	SoDonHang	MaSanPham	TenKH	DiaChiKH
23003	10021	90008	Toàn	số 1 Đường A
23003	10021	50034	Toàn	số 1 Đường A
<i>23003</i>	<i>10021</i>	<i>73006</i>	<i>Toàn</i>	<i>số 1 Đường A</i>
23009	22038	90008	Phương	số 4 Đường B
23013	23001	50034	Chính	số 9 Đường D
<i>23019</i>	<i>34062</i>	<i>73006</i>	<i>Tàn</i>	<i>số 1 Đường A</i>

Khách hàng Tàn và Toàn với hai mã khách hàng khác nhau nhưng lại có cùng giá trị địa chỉ, điều đó xác định họ chính là một người => có 1 bảng ghi sai chính tả tên khách hàng => loại bỏ trùng lặp => 2 bảng ghi này của cùng 1 khách hàng.



Làm sạch dữ liệu

Giới hạn vùng giá trị: Giá trị nằm ngoài miền giá trị cho phép (thông tin chứa các giá trị không hợp lệ theo một quy tắc nào đó) => mâu thuẫn trong các vùng dữ liệu (khó phát hiện)

Để sửa chữa mâu thuẫn, ta dùng giá trị NULL để thay thế vào những phần thông tin chưa biết trong các trường của bảng và cứ tiến hành sửa chữa các mâu thuẫn trong các vùng dữ liệu khác.



Làm sạch dữ liệu

Ví dụ:

Bảng 1.4: Bảng dữ liệu ví dụ

MaKh	SoDon Hang	MasanPham	TenKH	ĐịaChỉKh	Ngày ĐHang
23003	10021	90008	Toàn	số 1 Đường A	15/4/94
23003	10021	50034	Toàn	số 1 Đường A	21/6/93
23003	10021	73006	Toàn	số 1 Đường A	01/01/01
23009	22038	90008	Phương	số 4 Đường B	30/5/92
23013	23001	50034	Chính	số 9 Đường D	31/12/95
23003	34062	73006	Toàn	số 1 Đường A	21/01/94

Trường NgayĐHang có giá trị 01/01/01 => giá trị không hợp lý vì tại thời điểm đó siêu thị chưa thành lập => kiểm tra tính nhất quán miền giá trị => thay bằng giá trị NULL



Làm sạch dữ liệu

Bảng 1.5: Bảng dữ liệu ví dụ

MaKH	So DonHang	MaSanPham	TenKH	DiaChiKH	NgayDHng
23003	10021	90008	Toàn	số 1 Đường A	15/4/94
23003	10021	50034	Toàn	số 1 Đường A	21/6/93
23003	10021	73006	Toàn	số 1 Đường A	NULL
23009	22038	90008	Phương	số 4 Đường B	30/5/92
23013	23001	50034	Chính	số 9 Đường D	31/12/95



Làm sạch dữ liệu

Làm giàu dữ liệu: bổ sung thêm nhiều loại thông tin có liên quan vào CSDL gốc.

Cần có các CSDL khác bên ngoài có liên quan đến CSDL gốc ban đầu => bổ sung những thông tin cần thiết, làm tăng khả năng khám phá nhiều tri thức từ CSDL.



Làm sạch dữ liệu

Ví dụ:

Bảng 1.5: Bảng dữ liệu ví dụ

MaKH	So DonHang	MaSanPham	TenKH	DiaChiKH	NgayDHng
23003	10021	90008	Toàn	số 1 Đường A	15/4/94
23003	10021	50034	Toàn	số 1 Đường A	21/6/93
23003	10021	73006	Toàn	số 1 Đường A	NULL
23009	22038	90008	Phương	số 4 Đường B	30/5/92
23013	23001	50034	Chính	số 9 Đường D	31/12/95

Bảng 1.6: Bảng dữ liệu

MaKh	NgaySinh	ThuNhap	TinDung	SoHuu
23003	13/4/76	\$ 1,200,000.00	\$ 12,000,000.00	có
23009	20/10/71	\$ 3,600,000.00	\$ 50,000,000.00	có
23013	30/8/69	\$ 200,000.00	\$ 0.00	không
23021	4/9/67	\$ 500,000.00	\$ 200,000	không



Làm sạch dữ liệu

Vấn đề đặt ra là làm thế nào để kết hợp thông tin giữa dữ liệu gốc và dữ liệu được bổ sung. Bên cạnh đó cần lưu ý đến vấn đề khôi phục các quan hệ trong CSDL sau khi đã được làm giàu thông tin.



Làm sạch dữ liệu

- Phương pháp chia giỏ (Binning)
- **Chia theo độ rộng:**
 - Chia vùng giá trị thành N khoảng cùng kích thước, độ rộng của từng khoảng bằng (giá trị lớn nhất - giá trị nhỏ nhất)/N
 - **Ví dụ:** Có dãy 64 65 67 69 70 71 72 72 75 75 80 81 83 85

với $N = 7$ khoảng, Biên trái $\leq$ giá trị $<$ biên phải

64 67	67 70	70 73	73 76	76 79	79 82	82 85
-------	-------	-------	-------	-------	-------	-------

Dãy mới 1 1 2 2 3 3 3 3 4 4 6 6 7 7 được chuẩn hóa



Làm sạch dữ liệu

- Phương pháp chia giỏ (Binning)
- **Chia theo độ rộng:**
 - Chia vùng giá trị thành N khoảng cùng kích thước, độ rộng của từng khoảng bằng (giá trị lớn nhất - giá trị nhỏ nhất)/N

Bài tập : Có dãy 64 65 67 69 70 71 72 72 75 75 80 81 83 84

với $N = 5$ khoảng, hãy sử dụng phương pháp chia giỏ theo độ rộng cho dãy trên, và cho biết dãy mới đã được chuẩn hóa.



Làm sạch dữ liệu

- **Chia theo độ rộng:**
- Khi dữ liệu lệch nhiều thì sao?
- Ví dụ: Mức lương trong một công ty

170 200 210 40040000 50000. Trong đó lương mức 170 200 chiếm hơn 80% → chia theo độ rộng không phù hợp.



Làm sạch dữ liệu

- **Chia theo độ sâu:**
 - Chia vùng giá trị thành N khoảng, mỗi khoảng có cùng số lượng mẫu (trừ khoảng cuối cùng)
 - **Ví dụ:** Dãy 4 8 15 21 21 24 25 28 34

4 8 15	21 21 24	25 28 34
--------	----------	----------

Dãy mới ???



Làm sạch dữ liệu

- **Tiến hành khử nhiễu (làm trơn dữ liệu):**
 - Khử nhiễu bằng giá trị trung vị: Biến đổi giá trị trong giỏ theo giá trị trung vị.
 - Khử nhiễu bằng giá trị trung bình: Biến đổi giá trị trong giỏ theo giá trị trung bình của các phần tử trong giỏ.
 - Khử nhiễu bằng giá trị biên: Xét các giá trị trong giỏ gần với biên nào nhất thì quy về biên đó.



Làm sạch dữ liệu

- **Ví dụ:** Dữ liệu về giá cả như sau (đơn vị \$)

- 4 8 15 21 21 24 25 28 34
- Chia giỏ theo độ sâu với $N = 3$
- Bin 1: 4 8 15
- Bin 2: 21 21 24
- Bin 3: 25 28 34

- **Khử nhiễu:** theo giá trị trung vị

- Bin 1: 8 8 8
- Bin 2: 21 21 21
- Bin 3: 28 28 28



Làm sạch dữ liệu

- **Ví dụ:** Dữ liệu về giá cả như sau (đơn vị \$)

- 4 8 15 21 21 24 25 28 34
- Chia giỏ theo độ sâu với $N = 3$
- Bin 1: 4 8 15
- Bin 2: 21 21 24
- Bin 3: 25 28 34

- **Khử nhiễu:** theo giá trị trung bình

- Bin 1: 9 9 9
- Bin 2: 22 22 22
- Bin 3: 29 29 29



Làm sạch dữ liệu

- **Ví dụ:** Dữ liệu về giá cả như sau (đơn vị \$)

- 4 8 15 21 21 24 25 28 34
- Chia giỏ theo độ sâu với $N = 3$
- Bin 1: 4 8 15
- Bin 2: 21 21 24
- Bin 3: 25 28 34

- **Khử nhiễu:** theo giá trị biên

- Bin 1: 4 4 15
- Bin 2: 21 21 24
- Bin 3: 25 25 34



Làm sạch dữ liệu

Bài tập: Cho dữ liệu giá cả (\$) 15, 17, 19, 25, 29, 31, 33, 41, 42, 45, 45, 47, 52, 52, 64

Dùng phương pháp chia giỏ theo độ rộng và độ sâu với $N = 4$.

Tiến hành khử nhiễu theo trung vị, trung bình, biên và nhận xét kết quả đạt được.



Làm sạch dữ liệu

Dữ liệu nhiễu


- Phương pháp hồi qui
 - Là phương pháp ghép một phương trình hồi qui vào một tập hợp các điểm số liệu.
 - Dùng để tìm ra được một mối quan hệ tốt nhất giữa hai thuộc tính (hoặc biến), từ đó một thuộc tính có thể dùng để dự đoán thuộc tính khác.



Làm sạch dữ liệu

Dữ liệu nhiễu

- Phương pháp hồi qui
- Hàm hồi qui





Làm sạch dữ liệu

Dữ liệu nhiễu


- Phương pháp gom cụm
 - Các giá trị tương tự nhau được tổ chức thành các nhóm hay “cụm”. Các giá trị rơi ra bên ngoài các nhóm này sẽ được xem xét để làm mịn, sau đó đưa chúng vào cụm phù hợp.



Làm sạch dữ liệu

Dữ liệu nhiễu

- Phương pháp gom cụm





Tích hợp dữ liệu

Là quá trình trộn dữ liệu từ các nguồn khác nhau vào một kho dữ liệu sẵn sàng cho quá trình khai thác.

Để đảm bảo tính tương đương của thông tin giữa các nguồn khi tích hợp cần xem xét các vấn đề sau:

- Vấn đề nhận dạng thực thể
- Vấn đề dư thừa
- Vấn đề mâu thuẫn giá trị dữ liệu



Tích hợp dữ liệu

- **Vấn đề nhận dạng thực thể**
 - Cùng một thực thể nhưng đôi khi có sự **biểu diễn khác nhau** trong nhiều nguồn dữ liệu.
 - **Ví dụ:**
 - Ở mức lược đồ thuộc tính id của khách hàng trong một cơ sở dữ liệu A và số hiệu custom trong một cơ sở dữ liệu B chỉ một thuộc tính.
 - Ở mức thể hiện giá trị $\{male, female\}$ của trường giới tính trong cơ sở dữ liệu A và $\{Nam, Nữ\}$ trong cơ sở dữ liệu B.



Tích hợp dữ liệu

- **Vấn đề dư thừa**

- Ví dụ thuộc tính doanh thu hàng năm và thuộc tính doanh thu quý trong một CSDL là dư thừa.
- **Phân tích sự tương quan:** chỉ ra mức độ một thuộc tính phụ thuộc vào thuộc tính kia → **Sự tương quan giữa hai thuộc tính cao có thể bỏ bớt 1 thuộc tính.**
- Với thuộc tính số: Đánh giá sự tương quan giữa hai thuộc tính A và B bằng cách tính hệ số tương quan theo công thức Karl Pearson.



Tích hợp dữ liệu

- **Vấn đề mâu thuẫn giá trị dữ liệu**
 - Cùng một thực thể, các giá trị thuộc tính đến từ các nguồn khác nhau có thể khác nhau về cách biểu diễn hay mã hóa.
- **Ví dụ:**
 - Dữ liệu ngày tháng 31/12/2016 hay 12/31/2016
 - Dữ liệu logic là {1, 0} hay {yes, no}.
 - Thuộc tính giá trong các hệ thống tiền tệ khác nhau.



Biến đổi dữ liệu

- Quá trình biến đổi hay kết hợp dữ liệu vào những dạng thích hợp cho quá trình khai phá dữ liệu
 - Làm trơn dữ liệu (smoothing)
 - Kết hợp dữ liệu (aggregation)
 - Tổng quát hoá (generalization)
 - Chuẩn hoá (normalization)



Biến đổi dữ liệu

- Phương pháp chuẩn hóa
 - Một thuộc tính được chuẩn hóa bằng cách ánh xạ một cách có tỉ lệ dữ liệu về một khoảng xác định ví dụ như 0.0 đến 1.0.
 - Chúng ta sẽ xem xét ba phương pháp: min-max, z-score, và thay đổi số chữ số phần thập phân.



Biến đổi dữ liệu

- Chuẩn hóa min-max
 - Giả sử rằng $\min_A$ và $\max_A$ là giá trị tối thiểu và tối đa của thuộc tính A. Chuẩn hóa min-max sẽ ánh xạ giá trị v của thuộc tính A thành v' trong khoảng $[\text{new_min}_A, \text{new_max}_A]$
 - $$v' = \frac{v - \min_A}{\max_A - \min_A} (\text{new_max}_A - \text{new_min}_A) + \text{new_min}_A$$



$$v' = \frac{v - \min_A}{\max_A - \min_A} (\text{new_max}_A - \text{new_min}_B) + \text{new_min}_A$$

Biến đổi dữ liệu

Ví dụ: Giả sử giá trị nhỏ nhất và lớn nhất cho thuộc tính “thu nhập bình quân” là \$12.000 và \$98.000. Chúng ta muốn ánh xạ giá trị \$73.600 về khoảng [0.0, 1.0].

- $v' = \frac{73.600 - 12.000}{98.000 - 12.000} (1.0 - 0) + 0 = 0.716$



Biến đổi dữ liệu

- Chuẩn hóa z-score

- Giá trị của một thuộc tính A được chuẩn hóa dựa vào độ lệch tiêu chuẩn và trung bình của A.
- Một giá trị v của thuộc tính A được ánh xạ thành v' như sau:

$$v' = \frac{v - \bar{A}}{\sigma_A}$$

- Trong đó: $\bar{A}$ là giá trị trung bình của A; σ_A là độ lệch chuẩn



Biến đổi dữ liệu

Ví dụ: Giả sử rằng giá trị trung bình và độ lệch chuẩn của thuộc tính “thu nhập” là 54000 và 16000. Với cách chuẩn hóa z-score, giá trị 73000 sẽ được chuyển thành $v' =$

$$\frac{v - \bar{A}}{\sigma_A} = \frac{73000 - 54000}{16000} = 1.1875$$

Bài tập: $X = \{-5.0, 1.11, 7.23, 17.6, 23.0\}$ chuẩn hóa 7.23 theo min-max, z – score



Biến đổi dữ liệu

- Chuẩn hóa thay đổi số chữ số phần thập phân
 - Số chữ số phần thập phân được di chuyển phụ thuộc vào giá trị tuyệt đối lớn nhất có thể có của thuộc tính A.
 - Khi đó giá trị v sẽ được ánh xạ thành v' bằng cách tính $v' = \frac{v}{10^j}$
 - Trong đó j là giá trị nguyên nhỏ nhất để thỏa mãn $\max(|v'|) < 1$

Ví dụ: Giả sử rằng các giá trị của thuộc tính A được ghi nhận nằm trong khoảng -986 đến 917. Hãy chuẩn hóa thay đổi số chữ số phần thập phân



Biến đổi dữ liệu

- Chuẩn hóa thay đổi số chữ số phần thập phân
 - Ví dụ: Giả sử rằng các giá trị của thuộc tính A được ghi nhận nằm trong khoảng -986 đến 917 → trị tuyệt đối lớn nhất là 986. Sau đó lấy các giá trị chia cho 1.000 ($j = 3$). Như vậy giá trị -986 sẽ chuyển thành -0.986 và 917 được chuyển thành 0.917.



Thu giảm dữ liệu

Tập dữ liệu được biến đổi đảm bảo các toàn vẹn, nhưng nhỏ/ít hơn nhiều về số lượng so với ban đầu.

Các chiến lược thu giảm:

- Tổng hợp
- Giảm chiều dữ liệu
- Nén dữ liệu
- Giảm số lượng
- Rời rạc hóa (discretization)



Thu giảm dữ liệu

Tổng hợp

- Tổng hợp từ 2 thuộc tính dữ liệu trở lên thành một thuộc tính.

Year 2004	
Quarter	Sales
Q1	0
Q2	0
Q3	0
Q4	0

Year 2003	
Quarter	Sales
Q1	0
Q2	0
Q3	0
Q4	0

Year 2002	
Quarter	Sales
Q1	\$224,000
Q2	\$408,000
Q3	\$350,000
Q4	\$586,000

Sum()

Year	Sales
2002	\$1,568,000
2003	\$2,356,000
2004	\$3,594,000



Thu giảm dữ liệu

Lựa chọn tập thuộc tính con

- Chỉ chọn những thuộc tính phù hợp cho bài toán phân tích cụ thể.
- Ví dụ nếu nhiệm vụ phân tích chỉ liên quan đến việc phân loại khách hàng xem họ có hoặc không muốn mua một đĩa nhạc mới hay không → thuộc tính điện thoại không quan trọng bằng thuộc tính tuổi tác



Thu giảm dữ liệu

Lựa chọn tập thuộc tính con

- Thông qua các phép kiểm thống kê để xác định thuộc tính nào là tốt (xấu).
- Kỹ thuật lựa chọn tăng dần: Xuất phát từ tập rỗng các thuộc tính, các thuộc tính tốt nhất mỗi khi xác định được thêm vào, lặp lại khi không thêm được thuộc tính nào nữa.



Thu giảm dữ liệu


Lựa chọn tập thuộc tính con

- Kỹ thuật loại bớt: Xuất phát từ tập đầy đủ các thuộc tính, ở mỗi bước loại ra thuộc tính tồi nhất.
- Kết hợp giữa phương pháp loại bớt và lựa chọn tăng dần bằng cách tại mỗi bước ngoài việc lựa chọn thêm các thuộc tính tốt nhất đưa vào tập thì cũng đồng thời loại bỏ đi các thuộc tính tồi nhất khỏi tập đang xét.
- Cây quyết định: Cây được xây dựng từ nguồn dữ liệu ban đầu. Tất cả thuộc tính không xuất hiện trên cây được coi là không hữu ích.



Thu giảm dữ liệu

Lựa chọn tập thuộc tính con

Lựa chọn tăng dần	Loại bớt	Cây quyết định
Tập thuộc tính ban đầu $\{A1, A2, A3, A4, A5, A6\}$ Tập rút gọn ban đầu $\{\}$ $\Rightarrow \{A1\}$ $\Rightarrow \{A1, A4\}$ $\Rightarrow$ Kết quả $\{A1, A4, A6\}$	Tập thuộc tính ban đầu $\{A1, A2, A3, A4, A5, A6\}$ $\Rightarrow \{A1, A3, A4, A5, A6\}$ $\Rightarrow \{A1, A4, A5, A6\}$ $\Rightarrow$ Kết quả $\{A1, A4, A6\}$	Tập thuộc tính ban đầu $\{A1, A2, A3, A4, A5, A6\}$ $\Rightarrow$ Kết quả $\{A1, A4, A6\}$  <pre>graph TD; A4["A4?"] -- Y --> A1["A1?"]; A4 -- N --> A6["A6?"]; A1 -- Y --> C1_1((Class 1)); A1 -- N --> C2_1((Class 2)); A6 -- Y --> C1_2((Class 1)); A6 -- N --> C2_2((Class 2));</pre>
Bảng 3.2. Ví dụ kỹ thuật rút gọn		



Bài tập

1. Cho mảng một chiều $X = \{-5.0, 1.11, 7.23, 17.6, 23.0\}$, hãy chuẩn hóa mảng sử dụng
 - a/ Phương pháp chuẩn hóa Min-Max: trong khoảng $[-1, 1]$.
 - b/ Phương pháp chuẩn hóa Min-Max : trong khoảng $[0, 1]$.
 - c/ Phương pháp chuẩn hóa Min-Max : trong khoảng $[-1, 1]$.
 - d/ Phương pháp chuẩn hóa z-core
 - e/ Phương pháp chuẩn hóa thay đổi số chữ số phần thập phân



Bài tập

2. . Cho mảng dữ liệu $Y = \{1.17, 1.73, 2.59, 2.53, 2.67, 3.28, 3.38, 3.44, 4.23\}$

Hãy chuẩn hóa mảng sử dụng

a/ Phương pháp chuẩn hóa Min-Max: trong khoảng $[-1, 1]$.

b/ Phương pháp chuẩn hóa Min-Max : trong khoảng $[0, 1]$.

c/ Phương pháp chuẩn hóa Min-Max : trong khoảng $[-1, 1]$.

d/ Phương pháp chuẩn hóa z-core

e/ Phương pháp chuẩn hóa thay đổi số chữ số phần thập phân

f/ Phương pháp chia giỏ theo độ rộng với $N = 4$

g/ Phương pháp chia giỏ theo độ sâu với $N = 3$,

Hãy khử nhiễu theo giá trị biên, theo giá trị trung bình, theo giá trị trung vị.