



GOM CỤM DỮ LIỆU



NỘI DUNG

- Giới thiệu
- Độ đo khoảng cách
- Các phương pháp gom cụm



Giới thiệu

Gom nhóm (clustering): là quá trình nhóm/tập hợp các đối tượng thành những nhóm/cụm/lớp sao cho:

- Các đối tượng cùng cụm có độ **tương tự** cao.
- Và rất **khác** với đối tượng ở các cụm còn lại.



Giới thiệu

Cho CSDL $D=\{t_1, t_2, \dots, t_n\}$ và số nguyên k , gom nhóm là bài toán xác định ánh xạ $f: D \rightarrow \{1\dots k\}$ sao cho mỗi t_i được gán vào một cụm k_j ($1 \leq j \leq k$).

Chỉ biết được số cụm nhưng không biết các cụm là gì (không biết nhãn)?



Giới thiệu

Gom nhóm là dạng *học không giám sát* (unsupervised learning) bởi vì nhãn/lớp không được định trước.


Vì vậy, gom nhóm là dạng *học dựa trên quan sát* (learning by observation) hơn là *học dựa trên mẫu* (learning by examples)




Giới thiệu

Biểu diễn các nhóm

Phân chia bằng các đường ranh giới



Các hình khối



Theo xác suất

...



Giới thiệu

Ứng dụng:

1. **Tiền xử lý** cho quá trình khác (nhận dạng, phân lớp...)

2. Hỗ trợ **ra quyết định**

+ Bài toán phân tích phát hiện xu hướng khách hàng,

+ Bài toán phát hiện xâm nhập mạng trái phép,

+ Sử dụng thẻ tín dụng gian lận.

+ Tiếp thị nghiên cứu sở thích khách hàng.



Giới thiệu

Ứng dụng:

3. WWW

- + Gom nhóm tài liệu liên quan để dễ tìm kiếm.
- + Gom dữ liệu Weblog thành nhóm để tìm các nhóm có cùng kiểu truy cập.

4. Giảm kích thước dữ liệu lớn



Giới thiệu

Ví dụ:

- + Góm nhóm gen và protein có cùng chức năng (xây dựng công thức thuốc phù hợp)
- + Nhóm các cổ phiếu có xu hướng giá dao động giống nhau (quyết định đầu tư chính xác)
- + Nhóm các vùng theo lượng mưa ở Úc





Giới thiệu

Ví dụ:

- + Tiếp thị: phát hiện các nhóm khách hàng trong CSDL khách hàng để xây dựng chương trình tiếp thị có mục tiêu.
- + Đất đai: xác định các vùng đất trồng trọt giống nhau trong CSDL quan sát trái đất



Đánh giá kết quả gom nhóm

Tiêu chuẩn gom nhóm


Chất lượng của kết quả gom nhóm dựa trên hai yếu tố:

- **Độ đo sự giống nhau** dùng trong phương pháp gom nhóm
- **Thời gian** thực hiện quá trình gom nhóm

Một số độ đo chất lượng: Entropy, bình phương sai, độ đo khoảng cách ...

Độ đo khoảng cách

Euclidean distance



```
1 #Similarity Measures in Python
2 #Euclidean distance
```


```
1 from math import *
2 def euclidean_distance(x,y):
3     return sqrt(sum(pow(a-b,2) for a, b in zip(x, y)))
4 print(euclidean_distance([0,3,4,5],[7,6,3,-1]))
```

Độ đo khoảng cách

Manhattan distance:

$p(x_1, y_1), p_2(x_2, y_2)$.

Manhattan distance $(p_1, p_2) = |x_1 - x_2| + |y_1 - y_2|$




```
1 #Manhattan distance
2 from math import*
3 def manhattan_distance(x,y):
4     return sum(abs(a-b) for a,b in zip(x,y))
5 manhattan_distance([10,20,10],[10,20,20])
```

Độ đo khoảng cách

Cosine similarity

Cosine Similarity



```
1 #cosine similarity
2 from math import*
3 def square_rooted(x):
4     return round(sqrt(sum([a*a for a in x])),3)
5 def cosine_similarity(x,y):
6     numerator = sum(a*b for a,b in zip(x,y))
7     denominator = square_rooted(x)*square_rooted(y)
8     return round(numerator/float(denominator),3)
9
10 cosine_similarity([3, 45, 7, 2], [2, 54, 13, 15])
```

Độ đo khoảng cách

Jaccard similarity

Jaccard Similarity



$$\begin{aligned} \text{Jaccard Similarity } J(A,B) &= | \text{Intersection} (A,B) | / | \text{Union} (A,B) | \\ &= 2 / 7 \\ &= 0.286 \end{aligned}$$

```

1 #Jaccard Similarity
2 from math import*
3 def jaccard_similarity(x,y):
4     intersection_cardinality = len(set.intersection(*[set(x), set(y)]))
5     union_cardinality = len(set.union(*[set(x), set(y)]))
6     return intersection_cardinality/float(union_cardinality)
7 jaccard_similarity([0, 1, 2, 5, 6], [0, 2, 3, 5, 7])

```



II. Đánh giá kết quả gom nhóm

Một gom nhóm tốt?

Một phương pháp gom nhóm tốt sẽ phải tạo ra các cụm có chất lượng cao:

- Độ tương tự trong cụm cao.
- Độ tương tự với các cụm khác thấp.



Đánh giá kết quả gom nhóm

Chất lượng của việc gom nhóm phụ thuộc vào:

- Độ đo sự tương tự
- Sự thực thi của kỹ thuật gom nhóm (tốc độ)
- Khả năng khám phá ra một số hay tất cả mẫu tiềm ẩn



Đánh giá kết quả gom nhóm

Tiêu chí gom nhóm?

Cùng một tập dữ liệu nhưng với **tiêu chí khác** nhau thì sẽ có các **nhóm khác** nhau:


Ví dụ:

Khi gom nhóm các ngôi nhà, tùy theo tiêu chí gom nhóm là khoảng cách địa lý, kích thước, giá trị ... → nhóm khác nhau.

Gom nhóm SV theo học lực, sở thích âm nhạc, tỉnh thành ...


Đánh giá kết quả gom nhóm

VÍ DỤ : Gom nhóm các ngôi nhà



Đánh giá kết quả gom nhóm

VÍ DỤ : Gom nhóm các ngôi nhà



Dựa trên kích thước



Đánh giá kết quả gom nhóm

Tọa độ X	Tọa độ Y	Kích thước	Mức độ bền vững	Phong cách hiện đại
3	4	200	45	8
20	17	187	23	10
8	9	100	27	5.4
14	6	132	56	4.5
5	2	124	20	5
12	34	58	34	9.5
4	2	140	32	5.2



Phân loại các PP gom nhóm

Phương pháp phân hoạch

- Hình thành các phân hoạch và đánh giá chúng dựa trên một số tiêu chí.
- Các thuật toán: **k-means**, **k-medoids**

Phương pháp phân tầng

- Tạo ra sự phân chia các tầng
- Các thuật toán: Diana, Agnes



Phương pháp phân hoạch

- **Phân hoạch (Partitioning Clustering):** Là phương pháp đơn giản và nền tảng nhất trong số các phương pháp gom nhóm.
- Ý tưởng: **phân hoạch** một cơ sở dữ liệu D gồm n đối tượng thành tập **k nhóm** (k cho trước) **sao cho tối ưu tiêu chí phân hoạch**.



Phương pháp phân hoạch

- Biểu diễn mỗi cụm bằng **giá trị trung bình** của dữ liệu trong cụm đó: thuật toán K-means (1967).
- Biểu diễn cụm bằng một **đối tượng nằm gần trung tâm** của cụm nhất: thuật toán K-medoids, PAM (1987).



1. Thuật toán K - Means

Cho trước số k , mỗi cụm được biểu diễn bằng giá trị trung bình của cụm.

B1: Chọn ngẫu nhiên k đối tượng làm trung tâm của các cụm

B2: Gán từng đối tượng còn lại vào cụm gần nhất dựa trên độ đo khoảng cách như Euclidean, độ tương tự Cosine, correlation, ...

B3: Tính lại giá trị trung tâm của từng cụm dựa trên các đối tượng mới gia nhập.


B4: Nếu các trung tâm cụm không có gì thay đổi hay chỉ còn một ít điểm thay đổi n cụm thì dừng, ngược lại quay lại B2.



1. Thuật toán K - Means


Ví dụ: $k = 3$;

B1: Chọn 3 trung tâm cụm bất kỳ: k_1, k_2, k_3




1. Thuật toán K - Means

B2: Gán từng điểm vào cụm có trung tâm gần nhất




1. Thuật toán K - Means

B3: Di chuyển trung tâm cụm về điểm trung bình mới của cụm



1. Thuật toán K - Means

Gán lại các điểm cho gần trung tâm cụm mới





1. Thuật toán K - Means

Chất lượng của nhóm

Chất lượng của cụm C_i có thể được đo bằng độ biến đổi bên trong cụm hay bằng ***tổng bình phương sai (SSE- Sum of the Squared Errors)*** khoảng cách của tất cả đối tượng trong cụm đến trung tâm:



1. Thuật toán K - Means

Chất lượng của nhóm

$$SSE = \sum_{i=1}^k \sum_{p \in C_i} (dist(p, c_i))^2$$

c_i là trung tâm (centroid) của nhóm C_i

p là đối tượng trong C_i

k là số cụm

$dist$ là hàm tính khoảng cách



1. Thuật toán K - Means

Ví dụ 1: Cho dữ liệu $\{2,4,10,12,3,20,30,11,25\}$ và $k=2$. Dùng thuật toán K-means để xác định các cụm.

- B1: chọn ngẫu nhiên trung tâm cụm $m_1=3$; $m_2=4$
- B2: gán các đối tượng vào 2 cụm
- $K_1 = \{2,3\}$
- $K_2 = \{4,10,12,20,30,11,25\}$

Chất lượng nhóm tính theo tổng bình phương sai

$$SSE=1^2+0+0+6^2+8^2+16^2+26^2+7^2+21^2 = 1523$$



1. Thuật toán K - Means

$\{2, 4, 10, 12, 3, 20, 30, 11, 25\}$

- $K_1 = \{2, 3\}$

- $K_2 = \{4, 10, 12, 20, 30, 11, 25\}$

B3: Tính lại trung tâm cụm bằng công thức trung bình cộng:

$$m1 = (2+3)/2 = 2.5$$

$$m2 = (4+10+12+20+30+11+25)/7 = 16$$

Quay lại bước 2, gán các đối tượng vào 2 cụm thu được:

$$K_1 = \{2, 3, 4\}$$

$K_2 = \{10, 12, 20, 30, 11, 25\} \rightarrow$ hai cụm mới nên tiếp tục tính lại



1. Thuật toán K - Means

$$K_1 = \{2, 3, 4\}$$

$$K_2 = \{10, 12, 20, 30, 11, 25\}$$

tính lại $\rightarrow$ trung tâm cụm $m_1 = 3$; $m_2 = 18 \rightarrow$ gán lại các cụm

$$K_1 \{2, 3, 4, 10\}$$

$$K_2 \{12, 20, 30, 11, 25\} \text{ trung tâm cụm mới là } m_1 = 4.75, m_2 = 19.6$$



1. Thuật toán K - Means

...

Thu được trung tâm cụm cuối cùng 7 và 25 tương ứng 2 cụm thu được là $k1=\{2,3,4,10,11,12\}$ và $k2=\{20,30,25\}$.

Thuật toán dừng vì trung tâm cụm không thay đổi nữa.

$$SSE = 5^2+4^2+3^2+3^2+4^2+5^2+5^2+5^2+0 = 150.$$



1. Thuật toán K - Means

Ví dụ 2:

Sử dụng thuật toán k-means và khoảng cách Euclide để phân 8 điểm vào 3 cụm: $A_1=(2,10)$, $A_2=(2,5)$, $A_3=(8,4)$, $B_1=(5,8)$, $B_2=(7,5)$, $B_3=(6,4)$, $C_1=(1,2)$, $C_2=(4,9)$.

Vị trí của 3 điểm khởi đầu là $k_1 = A_1$, $k_2 = B_1$ và $k_3 = C_1$.



1. Thuật toán K - Means

Tính khoảng cách Euclide giữa các điểm

	A_1	A_2	A_3	B_1	B_2	B_3	C_1	C_2
A_1	0	$\sqrt{25}$	$\sqrt{64}$	$\sqrt{13}$	$\sqrt{50}$	$\sqrt{52}$	$\sqrt{65}$	$\sqrt{5}$
B_1	$\sqrt{13}$	$\sqrt{18}$	$\sqrt{25}$	0	$\sqrt{13}$	$\sqrt{17}$	$\sqrt{52}$	$\sqrt{2}$
C_1	$\sqrt{25}$	$\sqrt{10}$	$\sqrt{53}$	$\sqrt{52}$	$\sqrt{45}$	$\sqrt{29}$	0	$\sqrt{58}$

Xét khoảng cách các điểm so với 3 điểm $k_1 = A_1$, $k_2 = B_1$ và $k_3 = C_1$, gần k_i nhất thì đưa vào cụm thứ i .

Các cụm khi chạy K-Means lần 1

1: $\{A_1\}$

2: $\{A_3, B_1, B_2, B_3, C_2, \}$

3: $\{A_2, C_1, \}$



1. Thuật toán K - Means

$$A_1=(2,10), A_2=(2,5), A_3=(8,4), B_1=(5,8), B_2=(7,5), B_3=(6,4), C_1=(1,2), C_2=(4,9).$$

Các cụm khi chạy K-Means lần 1

$$1: \{A_1\}$$

$$2: \{A_3, B_1, B_2, B_3, C_2, \}$$

$$3: \{A_2, C_1, \}$$

Tính lại trung tâm các cụm mới

$$k_1=(2,10)$$

$$k_2=\left(\frac{8+5+7+6+4}{5}, \frac{4+8+5+4+9}{5}\right) = (6,6)$$

$$k_3=\left(\frac{2+1}{2}, \frac{5+2}{2}\right) = (1.5, 3.5)$$



1. Thuật toán K - Means

Chạy K-Means lần 2 với các trung tâm cụm mới $k_1=(2,10)$, $k_2=(6,6)$, $k_3=(1.5,3.5)$.

1: $\{A_1, C_2\}$

2: $\{A_3, B_1, B_2, B_3\}$

3: $\{A_2, C_1\}$

Tính lại trung tâm các cụm mới $k_1=(3, 9.5)$, $k_2=(6.5, 5.25)$, $k_3=(1.5, 3.5)$



1. Thuật toán K - Means

Chạy K-Means lần 3 với các trung tâm cụm mới $k_1=(3, 9.5)$, $k_2=(6.5, 5.25)$, $k_3=(1.5, 3.5)$

1: $\{A_1, B_1, C_2\}$

2: $\{A_3, B_2, B_3\}$

3: $\{A_2, C_1\}$

Tính lại trung tâm các cụm mới $k_1=(3.66, 9)$, $k_2=(7, 4.33)$ và $k_3=(1.5, 3.5)$.



1. Thuật toán K - Means

Chạy K-Means lần 4 với các trung tâm các nhóm mới $k_1 = (3.66, 9)$, $k_2 = (7, 4.33)$ và $k_3 = (1.5, 3.5)$.

1: $\{A_1, B_1, C_2\}$

2: $\{A_3, B_2, B_3\}$

3: $\{A_2, C_1\}$

Không đổi $\rightarrow$ dừng thuật toán



1. Thuật toán K - Means

Bài tập 1:

Cho dữ liệu $\{2,3,4,10,11,12,20,25,30\}$ và $k=2$.

Dùng thuật toán K-means để xác định các cụm khi chọn trung tâm $m_1=5$; $m_2=10$.

Tính SSE cho từng cụm ở vòng lặp đầu tiên và cuối cùng.
Qua đó cho biết ý nghĩa của giá trị SSE.



1. Thuật toán K - Means

Bài tập 2:

Cho dữ liệu $\{2,3,4,10,11,12,20,25,30\}$ và $k=2$.

Dùng thuật toán K-means để xác định các cụm khi chọn trung tâm $m_1=4$; $m_2=12$.

Tính SSE cho từng cụm ở vòng lặp đầu tiên và cuối cùng. Qua đó cho biết ý nghĩa của giá trị SSE.



1. Thuật toán K - Means

Bài tập 3:

Cho dữ liệu {2,4,10,12,3,20,30,11,25} và $k=2$.

Dùng thuật toán K-means để xác định các cụm khi chọn trung tâm $m_1=5$; $m_2=10$.

Tính SSE cho từng cụm ở vòng lặp đầu và cuối. Qua đó cho biết ý nghĩa của giá trị SSE.



1. Thuật toán K - Means

Nhận xét:

- Ưu điểm:
 - Đơn giản, hiệu quả.
 - Độ phức tạp $O(tkn)$; $t, k \ll n$.
 - Đạt được tối ưu cục bộ.



1. Thuật toán K - Means

- Khuyết điểm:
 - Chỉ áp dụng được với đối tượng trong không gian n-chiều liên tục
 - Cần xác định số nhóm k trước
 - Nhạy cảm với dữ liệu nhiễu và cá biệt vì mọi đối tượng đều phải gán vào cụm gây ra sự hỗn loạn.



2. Thuật toán K - Medoids

- **Thuật toán k-medoids:** thay vì lấy giá trị trung tâm làm điểm đối chiếu, k-medoids lấy đối tượng nằm ở *vị trí trung tâm* của cụm



2. Thuật toán K - Medoids

Thuật toán PAM (Partitioning Around Medoids) đại diện tiêu biểu của K-Medoids

B1: Chọn tùy ý k đối tượng như là trung tâm của k cụm.

B2: Gán từng đối tượng còn lại vào cụm k sao cho khoảng cách từ nó đến k là nhỏ nhất.

B3: Chọn một đối tượng bất kỳ trong cụm, hoán đổi nó với trung tâm cụm. Nếu chất lượng của cụm tăng lên thì quay lại **B2**. Ngược lại, thực hiện **B3** cho đến khi không còn có sự thay đổi.



2. Thuật toán K - Medoids

PAM sử dụng độ đo khoảng cách **Manhattan**

$$d(p, q) = \sum_{i=1}^n |p_i - q_i|$$

Với $p = (p_1, p_2, \dots, p_n)$; $q = (q_1, q_2, \dots, q_n)$



2. Thuật toán K - Medoids

Ví dụ: phân các điểm sau vào 2 cụm $X_1(2,6)$, $X_2(3,4)$, $X_3(3,8)$, $X_4(4,7)$, $X_5(6,2)$, $X_6(6,4)$, $X_7(7,3)$, $X_8(7,4)$, $X_9(8,5)$, $X_{10}(7,6)$

B1: Chọn hai điểm ngẫu nhiên làm trung tâm cụm : chọn trung tâm $C_1=X_2(3,4)$ và $C_2=X_8(7,4)$.

B2: Tính khoảng cách các điểm đến trung tâm C_1 và C_2 , khoảng cách nào nhỏ hơn thì đưa vào cụm đó.



2. Thuật toán K - Medoids

Khoảng cách các điểm đến trung tâm			
i	X_i	$C_1=(3,4)$	$C_2=(7,4)$
1	(2, 6)	3	7
2	(3, 4)	0	4
3	(3, 8)	4	8
4	(4, 7)	4	6
5	(6, 2)	5	3
6	(6, 4)	3	1
7	(7, 3)	5	1
8	(7, 4)	4	0
9	(8, 5)	6	2
10	(7, 6)	6	2
Tổng		11	9



IV.2 Thuật toán K - Medoids

- Được các cụm như sau

$$\text{Cluster}_1 = \{(3,4)(2,6)(3,8)(4,7)\}$$

$$\text{Cluster}_2 = \{(7,4)(6,2)(6,4)(7,3)(8,5)(7,6)\}$$

Và tổng khoảng cách là 20

B3: Chọn lần lượt các C'_1/C'_2 trong $\text{Cluster}_1/\text{Cluster}_2$ thay cho C_1/C_2 tính lại khoảng cách nếu nhỏ hơn giá trị 20 thì quay lại **B2**.



2. Thuật toán K - Medoids

- Giả sử chọn $C'_2 = (7, 3)$
- Khoảng cách $= 22 > 20$
- Tiếp tục B3
- ...

Khoảng cách các điểm đến trung tâm			
i	X_i	$C_1=(3,4)$	$C_2=(7,3)$
1	(2, 6)	3	8
2	(3, 4)	0	5
3	(3, 8)	4	9
4	(4, 7)	4	7
5	(6, 2)	5	2
6	(6, 4)	3	2
7	(7, 3)	5	0
8	(7, 4)	4	1
9	(8, 5)	6	3
10	(7, 6)	6	3
Tổng		11	11



2. Thuật toán K - Medoids

Bài tập

Cho dữ liệu $\{2,4,10,12,3,20,30,11,25\}$ và $k=2$. Dùng thuật toán PAM để xác định các cụm khi chọn trung tâm $C_1=4; C_2=11$.



Nhận xét PAM

- k-medoids tốt hơn k-means trong việc xử lý nhiễu.
- Làm việc hiệu quả đối với dữ liệu nhỏ nhưng không hiệu quả trong tập dữ liệu lớn.




Phương pháp phân cấp

Hierarchical Clustering là phương pháp sinh ra tập các cụm lồng nhau được tổ chức như một **cây phân cấp**.



Phương pháp phân cấp


Phương pháp phân cấp không cần xác định trước số cụm k .





Phương pháp phân cấp

Với sơ đồ ở dưới nếu cắt ngang cây ở vị trí 0.15 được 4 cụm, cắt ở vị trí 0.2 thì được hai cụm.



Phương pháp phân cấp

■ 6 Italian cities

	BA	FI	MI	NA	RM	TO
BA	0	662	877	255	412	996
FI	662	0	295	468	268	400
MI	877	295	0	754	564	138
NA	255	468	754	0	219	869
RM	412	268	564	219	0	669
TO	996	400	138	869	669	0



Phương pháp phân cấp

	BA	FI	MI/TO	NA	RM
BA	0	662	877	255	412
FI	662	0	295	468	268
MI/TO	877	295	0	754	564
NA	255	468	754	0	219
RM	412	268	564	219	0



- Trộn MI và TO.
- Tính lại khoảng cách nhỏ nhất từ cụm MI/TO đến tất cả các cụm khác

Phương pháp phân cấp

	BA	FI	MI/TO	NA/RM
BA	0	662	877	255
FI	662	0	295	268
MI/TO	877	295	0	564
NA/RM	255	268	564	0



- Trộn NA và RM.

Phương pháp phân cấp

	BA/NA/RM	FI	MI/TO
BA/NA/RM	0	268	564
FI	268	0	295
MI/TO	564	295	0



Trộn BA và NA/RM.

Phương pháp phân cấp


	BA/FI/NA/RM	MI/TO
BA/FI/NA/RM	0	295
MI/TO	295	0



Trộn FI và BA/NA/RM.



Phương pháp phân cấp





Phương pháp phân cấp

Có 2 cách gom nhóm theo phương pháp phân cấp: Tích tụ và phân rã

– ***Tích tụ***: thuật toán AGNES

- Bắt đầu với mỗi đối tượng như là cụm riêng biệt.
- Trong mỗi bước, tiến hành gom cặp cụm gần nhất cho đến khi chỉ còn 1 cụm.




Phương pháp phân cấp

– *Phân rã*: thuật toán DIANA

- Nhóm ban đầu bao gồm tất cả đối tượng
- Trong mỗi bước, tiến hành chia một cụm cho đến khi mỗi cụm chứa một đối tượng.



Phương pháp phân cấp





Phương pháp phân cấp

Độ đo khoảng cách giữa các cụm:

Độ đo **single link**: khoảng cách **gần nhất** giữa hai đối tượng thuộc hai cụm

$$\text{dist}(K_i, K_j) = \min(t_{ip}, t_{jq})$$

Độ đo **complete link**: khoảng cách **xa nhất** giữa hai đối tượng thuộc hai cụm

$$\text{dist}(K_i, K_j) = \max(t_{ip}, t_{jq})$$



Phương pháp phân cấp

Độ đo **Average**: khoảng cách trung bình của phần tử trong cụm so với cụm khác

$$\text{dist}(K_i, K_j) = \text{avg}(t_{ip}, t_{jq})$$

Độ đo **Centroid**: khoảng cách giữa trung tâm hai cụm

$$\text{dist}(K_i, K_j) = \text{dist}(C_i, C_j)$$



Phương pháp phân cấp

Thuật toán AGNES (AGglomerative NESTing):

B1: Mỗi đối tượng là một cụm

B2: Nhóm các đối tượng mà khoảng cách giữa chúng là nhỏ nhất (Dùng độ đo Single link/Complete link)

B3: Nếu thu được cụm gồm toàn bộ tập dữ liệu thì dừng, ngược lại quay lại bước 2.



Phương pháp phân cấp

Ví dụ: cho tập DL gồm 6 điểm như sau: $P1(0.40, 0.53)$; $P2(0.22, 0.38)$; $P3(0.353, 0.32)$; $P4(0.26, 0.19)$; $P5(0.08, 0.41)$; $P6(0.45, 0.30)$.

Sử dụng AGNES với độ đo Single Link để gom nhóm



Phương pháp phân cấp

Ví dụ: Xây dựng ma trận khoảng cách bằng độ đo Euclide giữa các điểm.

B1: Mỗi điểm là 1 cụm

{1}, {2}, {3}, {4}, {5},

{6} ta có 6 cụm.

	P1	P2	P3	P4	P5	P6
P1	0	0.23	0.22	0.37	0.34	0.24
P2		0	0.15	0.19	0.14	0.24
P3			0	0.16	0.29	0.1
P4				0	0.28	0.22
P5					0	0.39
P6						0



Phương pháp phân cấp

B2: $\text{dist}(3,6) \text{ min} \rightarrow$ gộp thành 1 cụm $\{3,6\} \rightarrow$ 5 cụm $\{1\}, \{2\}, \{4\}, \{5\}, \{3,6\}$

Quay lại B2 do chưa thu được cụm toàn bộ

Tính khoảng cách giữa các cụm

$$+\text{Dist}(\{3,6\},\{1\}) = \min(\text{dist}(\{3\},\{1\}), \text{dist}(\{6\},\{1\})) = 0.22$$

$$+\text{Dist}(\{3,6\},\{2\}) = ?$$

$$+\text{Dist}(\{3,6\},\{4\}) = ?$$

$$+\text{Dist}(\{3,6\},\{5\}) = ?$$



Phương pháp phân cấp

$\text{dist}(2,5) \text{ min} \rightarrow$ gộp thành 1 cụm $\{2,5\} \rightarrow$ 4 cụm $\{1\}, \{4\}, \{2,5\}, \{3,6\}$

Quay lại B2 do chưa thu được cụm toàn bộ

Tính khoảng cách giữa các cụm

$$\text{Dist}(\{2,5\}, \{3,6\}) = \min(\text{dist}(\{3\}, \{2\}), \text{dist}(\{6\}, \{2\}), \text{dist}(\{3\}, \{5\}), \text{dist}(\{6\}, \{5\})) = 0.15$$

$$\text{Dist}(\{2,5\}, \{1\}) = ?$$

$$\text{Dist}(\{2,5\}, \{4\}) = ?$$



Phương pháp phân cấp

$\text{dist}(\{2,5\},\{3,6\}) \min \rightarrow$ gộp thành 1 cụm $\{2,5,3,6\} \rightarrow$ 3 cụm $\{1\}, \{4\}, \{2,5,3,6\}$

Quay lại B2 do chưa thu được cụm toàn bộ


Tính khoảng cách giữa các cụm

$\text{Dist}(\{3,6,2,5\},4) = ?$


$\text{Dist}(\{3,6,2,5\},1) = ?$

Để gộp vào cụm $\rightarrow$ 2 cụm $\{1\}, \{4,2,5,3,6\}$... được cụm toàn bộ thì dừng thuật

Phương pháp phân cấp



Các nhóm - single link



Hình cây



Bài tập

Cho tập DL gồm 6 điểm như sau: $P1(0.40, 0.53)$; $P2(0.22, 0.38)$; $P3(0.353, 0.32)$; $P4(0.26, 0.19)$; $P5(0.08, 0.41)$; $P6(0.45, 0.30)$. Sử dụng AGNES với độ đo CompleteLink để gom nhóm.



Nhận xét

1. **Gom nhóm** là quá trình **nhóm** các đối tượng thành những **cụm** sao cho các đối tượng cùng cụm có **độ tương tự cao** và **rất khác** với đối tượng ở các cụm còn lại.
2. Gom nhóm **phân hoạch** là pp đơn giản và **nền tảng** nhất trong số các pp gom nhóm dựa trên việc phân hoạch một cơ sở dữ liệu D thành k cụm (với k cho trước) sao cho tối ưu tiêu chí phân hoạch. Hai thuật toán điển hình là k -means và k -medoids.



Nhận xét

3. Gom nhóm phân cấp là phương pháp sinh ra tập các cụm lồng nhau được tổ chức như một cây phân cấp.

Có hai cách để phân cấp: phân cấp kiểu tích tụ điển hình là thuật toán AGNES và phân cấp kiểu phân rã điển hình là thuật toán DIANA.